

lab01

Laboratório 01

Importação e Manipulação de Dados em R

Eduardo Hsu - 277142

1. Carregue o pacote `tidyverse`

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2    4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()     masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

2. Apresente os bancos de dados `table1`, `table2`, `table3`, `table4a` e `table4b`, distribuídos juntamente com o pacote `tidyverse`. Para cada banco de dados, descreva textualmente se ele está no formato tidy e justifique cada uma de suas respostas.

```
head(table1)
```

```
# A tibble: 6 x 4
  country    year cases population
  <chr>      <dbl> <dbl>      <dbl>
1 Afghanistan 1999    745   19987071
2 Afghanistan 2000   2666   20595360
3 Brazil      1999  37737  172006362
4 Brazil      2000  80488  174504898
5 China       1999 212258 1272915272
6 China       2000 213766 1280428583
```

```
head(table2)
```

```
# A tibble: 6 x 4
  country    year type      count
  <chr>      <dbl> <chr>      <dbl>
1 Afghanistan 1999 cases        745
2 Afghanistan 1999 population 19987071
3 Afghanistan 2000 cases        2666
4 Afghanistan 2000 population 20595360
5 Brazil      1999 cases        37737
6 Brazil      1999 population 172006362
```

```
head(table3)
```

```
# A tibble: 6 x 3
  country    year rate
  <chr>      <dbl> <chr>
1 Afghanistan 1999 745/19987071
2 Afghanistan 2000 2666/20595360
3 Brazil      1999 37737/172006362
4 Brazil      2000 80488/174504898
5 China       1999 212258/1272915272
6 China       2000 213766/1280428583
```

```
head(table4a)
```

```
# A tibble: 3 x 3
  country `1999` `2000`
  <chr>    <dbl> <dbl>
1 Afghanistan    745    2666
2 Brazil        37737    80488
3 China        212258    213766
```

```
head(table4b)
```

```
# A tibble: 3 x 3
  country      `1999`      `2000`
  <chr>        <dbl>        <dbl>
1 Afghanistan 19987071    20595360
2 Brazil      172006362   174504898
3 China       1272915272  1280428583
```

Apenas a tabela ‘table1’ está no formato tidy. Nela, cada variável (país, ano, casos, população) tem sua própria coluna e cada observação ocupa uma única linha. A ‘table2’ não é tidy porque mistura variáveis diferentes (casos e população) nas linhas da coluna type. A ‘table3’ agrupa dois valores na mesma coluna rate. As ‘table4a’ e ‘table4b’ utilizam valores (anos) como nomes de colunas.

3. Utilizando comandos do pacote **dplyr**, determine a taxa de ocorrência de tuberculose para cada 10.000 pessoas. Armazene o resultado em um objeto chamado **taxas**.

```
taxas <- table1 %>%
  mutate(taxa_10k = (cases / population) * 10000)

taxas
```

```
# A tibble: 6 x 5
  country      year  cases population taxa_10k
  <chr>        <dbl> <dbl>        <dbl>    <dbl>
1 Afghanistan 1999     745    19987071     0.373
2 Afghanistan 2000    2666    20595360     1.29
3 Brazil      1999   37737   172006362     2.19
4 Brazil      2000   80488   174504898     4.61
5 China       1999  212258  1272915272     1.67
6 China       2000  213766  1280428583     1.67
```

4. Apresente, utilizando comandos do pacote **dplyr**, o número de casos de tuberculose por ano.

```
table1 %>%
  group_by(year) %>%
  summarise(total_casos_ano = sum(cases))
```

```
# A tibble: 2 x 2
  year total_casos_ano
  <dbl>         <dbl>
1  1999         250740
2  2000         296920
```

5. Apresente, utilizando comandos do pacote `dplyr`, o número de casos de tuberculose identificados em cada país.

```
table1 %>%
  group_by(country) %>%
  summarise(total_casos_pais = sum(cases))
```

```
# A tibble: 3 x 2
  country      total_casos_pais
  <chr>          <dbl>
1 Afghanistan      3411
2 Brazil           118225
3 China            426024
```


6. Utilizando comandos do pacote `dplyr`, apresente uma tabela que descreva a mudança no número de casos, em cada país, ao longo dos anos de 1999 e 2000.

```
table1 %>%
  select(country, year, cases) %>%
  pivot_wider(names_from = year, values_from = cases) %>%
  mutate(mudanca = `2000` - `1999`)
```

```
# A tibble: 3 x 4
  country      `1999` `2000` mudanca
  <chr>          <dbl> <dbl>   <dbl>
1 Afghanistan      745   2666    1921
2 Brazil          37737  80488   42751
3 China          212258 213766    1508
```

7. Apresente um gráfico de linhas, preparado via `ggplot2`, apresentando a mudança na taxa de casos (por 10.000 habitantes) estratificado por país.

```
ggplot(taxas, aes(x = year, y = taxa_10k, color = country)) +
  geom_line() +
  geom_point() +
  scale_x_continuous(breaks = c(1999, 2000)) +
  labs(title = "Taxa de Casos de Tuberculose por 10.000 Habitantes",
       x = "Ano",
       y = "Taxa por 10k habitantes")
```



8. Calcule a taxa para as tabelas `table2` e `table4a+table4b`. Para isso, você precisará executar 4 passos:
- Extrair o número de casos de tuberculose por país, por ano;
 - Extrair o tamanho da população correspondente, por ano;
 - Dividir o número de casos pelo tamanho da população e multiplicar o resultado por 10.000;
 - Armazenar o resultado numa variável apropriada;

```
taxas_table2 <- table2 %>%
  pivot_wider(names_from = type, values_from = count) %>%
  mutate(taxa_10k = (cases / population) * 10000)
```

```

casos_4a <- table4a %>%
  pivot_longer(cols = c(`1999`, `2000`), names_to = "year", values_to = "cases")

pop_4b <- table4b %>%
  pivot_longer(cols = c(`1999`, `2000`), names_to = "year", values_to = "population")

taxas_table4 <- left_join(casos_4a, pop_4b, by = c("country", "year")) %>%
  mutate(
    year = as.numeric(year),
    taxa_10k = (cases / population) * 10000
  )

taxas_table2

```

```

# A tibble: 6 x 5
  country    year cases population taxa_10k
  <chr>      <dbl> <dbl>      <dbl>    <dbl>
1 Afghanistan 1999     745   19987071    0.373
2 Afghanistan 2000    2666  20595360    1.29
3 Brazil      1999   37737  172006362    2.19
4 Brazil      2000   80488  174504898    4.61
5 China       1999  212258 1272915272    1.67
6 China       2000  213766 1280428583    1.67

```

```
taxas_table4
```

```

# A tibble: 6 x 5
  country    year cases population taxa_10k
  <chr>      <dbl> <dbl>      <dbl>    <dbl>
1 Afghanistan 1999     745   19987071    0.373
2 Afghanistan 2000    2666  20595360    1.29
3 Brazil      1999   37737  172006362    2.19
4 Brazil      2000   80488  174504898    4.61
5 China       1999  212258 1272915272    1.67
6 China       2000  213766 1280428583    1.67

```


9. Refaça o gráfico da questão 7 para os dados apresentados em `table2`.

```

ggplot(taxas_table2, aes(x = year, y = taxa_10k, color = country)) +
  geom_line() +
  geom_point() +

```

```
scale_x_continuous(breaks = c(1999, 2000)) +
labs(title = "Taxa de Casos de Tuberculose por 10.000 Habitantes",
     x = "Ano",
     y = "Taxa por 10k habitantes")
```



10. Utilizando o comando `pivot_longer`, transforme `table4a` em um objeto no formato tidy. Armazene o resultado num objeto chamado `tidy4a`.

```
tidy4a <- pivot_longer(table4a, cols = c(`1999`, `2000`),
                       names_to = "year", values_to = "cases")
tidy4a
```

```
# A tibble: 6 x 3
  country    year  cases
  <chr>      <chr> <dbl>
1 Afghanistan 1999     745
2 Afghanistan 2000    2666
3 Brazil      1999   37737
4 Brazil      2000   80488
5 China       1999  212258
6 China       2000  213766
```

11. Refaça o item 10 para o objeto `table4b`. Armazene o resultado num objeto chamado `tidy4b`.

```
tidy4b <- pivot_longer(table4b, cols = c(`1999`, `2000`),  
                        names_to = "year", values_to = "population")  
tidy4b
```

```
# A tibble: 6 x 3  
  country    year population  
  <chr>     <chr>      <dbl>  
1 Afghanistan 1999    19987071  
2 Afghanistan 2000    20595360  
3 Brazil      1999    172006362  
4 Brazil      2000    174504898  
5 China       1999   1272915272  
6 China       2000   1280428583
```

12. Combine os objetos `tidy4a` e `tidy4b` em um único objeto, utilizando o comando `left_join`. Apresente uma explicação textual sobre o que faz o referido comando.

```
tidy4 <- left_join(tidy4a, tidy4b, by = c("country", "year"))  
tidy4
```

```
# A tibble: 6 x 4  
  country    year  cases population  
  <chr>     <chr> <dbl>      <dbl>  
1 Afghanistan 1999     745    19987071  
2 Afghanistan 2000    2666    20595360  
3 Brazil      1999    37737   172006362  
4 Brazil      2000    80488   174504898  
5 China       1999   212258  1272915272  
6 China       2000   213766  1280428583
```

O comando `left_join` é utilizado para mesclar dois conjuntos de dados. Ele mantém todas as linhas da tabela da esquerda e adiciona as colunas da tabela da direita, alinhando as informações com base nas chaves em comum, que neste caso são as colunas `country` e `year`.

13. Use o comando `pivot_wider` para transformar o objeto `table2` em um objeto com formato `tidy`.

```
tidy2 <- pivot_wider(table2, names_from = type, values_from = count)
tidy2
```

```
# A tibble: 6 x 4
  country    year cases population
  <chr>      <dbl> <dbl>      <dbl>
1 Afghanistan 1999    745  19987071
2 Afghanistan 2000   2666  20595360
3 Brazil      1999  37737  172006362
4 Brazil      2000  80488  174504898
5 China       1999 212258 1272915272
6 China       2000 213766 1280428583
```

14. Observe que a coluna `rate` do objeto `table3` é um texto mostrando a fração que formaria a taxa de casos de tuberculose. Transforme o objeto `table3` em um objeto com formato tidy separando a coluna 3 em duas outras colunas: `cases` e `population`, utilizando o comando `separate`. Utilize o argumento `convert` para transformar o resultado em um objeto numérico.

```
tidy3 <- separate(table3, col = rate, into = c("cases", "population"), convert = TRUE)
tidy3
```

```
# A tibble: 6 x 4
  country    year cases population
  <chr>      <dbl> <int>      <int>
1 Afghanistan 1999    745  19987071
2 Afghanistan 2000   2666  20595360
3 Brazil      1999  37737  172006362
4 Brazil      2000  80488  174504898
5 China       1999 212258 1272915272
6 China       2000 213766 1280428583
```