

ME315A Lab02

Eduardo Hsu 277142

```
library(tidyverse)
```

1. Quais são as estatísticas suficientes para a determinação do percentual de vôos atrasados na chegada (`ARRIVAL_DELAY > 10`)?

As estatística suficientes são o número total de voos e o número total de voos com atrasos na chegada maior que 10 minutos.

2. Crie uma função chamada `getStats` que, para um conjunto de qualquer tamanho de dados provenientes de `flights.csv.zip`, execute as seguintes tarefas (usando apenas verbos do `dplyr`):
 - a. Filtre o conjunto de dados de forma que contenha apenas observações das seguintes Cias. Aéreas: AA, DL, UA e US;
 - b. Remova observações que tenham valores faltantes em campos de interesse;
 - c. Agrupe o conjunto de dados resultante de acordo com: dia, mês e cia. aérea;
 - d. Para cada grupo em b., determine as estatísticas suficientes apontadas no item 1. e os retorne como um objeto da classe `tibble`;
 - e. A função deve receber apenas dois argumentos:
 - f. `input`: o conjunto de dados (referente ao lote em questão);
 - ii. `pos`: argumento de posicionamento de ponteiro dentro da base de dados. Apesar de existir na função, este argumento não será empregado internamente. É importante observar que, sem a definição deste argumento, será impossível fazer a leitura por partes.

```
getStats <- function(input, pos) {  
  input %>%  
  filter(AIRLINE %in% c("AA", "DL", "UA", "US")) %>%  
  drop_na(ARRIVAL_DELAY) %>%  
  group_by(DAY, MONTH, AIRLINE) %>%  
  summarise(  
    voos_total = n(),  
    voos_atraso = sum(ARRIVAL_DELAY > 10)
```

```
)  
}
```

3. Utilize alguma função `readr::read_***_chunked` para importar o arquivo `flights.csv.zip`.
 - a. Configure o tamanho do lote (chunk) para 100 mil registros;
 - b. Configure a função de callback para instanciar DataFrames aplicando a função `getStats` criada acima;
 - c. Configure o argumento `col_types` de forma que ele leia, diretamente do arquivo, apenas as colunas de interesse (veja nota de aula para identificar como realizar esta tarefa);

```
# Nota: Lendo o arquivo "flights.csv" diretamente, pois o Posit Cloud  
# realiza a extração automática do .zip no ambiente virtual.  
dados_parciais <- read_csv_chunked("flights.csv",  
  callback = DataFrameCallback$new(getStats),  
  chunk_size = 100000,  
  col_types = cols_only(DAY = col_integer(),  
                        MONTH = col_integer(),  
                        ARRIVAL_DELAY = col_integer(),  
                        AIRLINE = col_character()))
```

4. Crie uma função chamada `computeStats` que:
 - a. Combine as estatísticas suficientes para compor a métrica final de interesse (percentual de atraso por dia/mês/cia aérea);
 - b. Retorne as informações em um tibble contendo apenas as seguintes colunas:
 - c. Cia: sigla da companhia aérea;
 - ii. Data: data, no formato AAAA-MM-DD (dica: utilize o comando `as.Date`);
 - iii. Perc: percentual de atraso para aquela cia. aérea e data, apresentado como um número real no intervalo [0,1].

```
computeStats <- function(dados_parciais){  
  dados_parciais %>%  
  group_by(AIRLINE, DAY, MONTH) %>%  
  summarise(atraso_total = sum(voos_atraso),  
            total_geral = sum(voos_total),  
            Perc = atraso_total/total_geral  
  ) %>%  
  mutate(Data = as.Date(paste("2015", MONTH, DAY, sep="-"))) %>%  
  select(Cia = AIRLINE, Data, Perc)  
}
```

```
estatisticas_finais <- computeStats(dados_parciais)
```

5. Produza um mapa de calor em formato de calendário para cada Cia. Aérea.
 - a. Instale e carregue os pacotes ggcal e ggplot2.
 - b. Defina uma paleta de cores em modo gradiente. Utilize o comando `scale_fill_gradient`. A cor inicial da paleta deve ser `#4575b4` e a cor final, `#d73027`. A paleta deve ser armazenada no objeto `pal`.
 - c. Crie uma função chamada `baseCalendario` que recebe 2 argumentos a seguir: `stats` (tibble com resultados calculados na questão 4) e `cia` (sigla da Cia. Aérea de interesse). A função deverá:
 - d. Criar um subconjunto de `stats` de forma a conter informações de atraso e data apenas da Cia. Aérea dada por `cia`.
 - ii. Para o subconjunto acima, montar a base do calendário, utilizando `ggcal(x, y)`. Nesta notação, `x` representa as datas de interesse e `y`, os percentuais de atraso para as datas descritas em `x`.
 - iii. Retornar para o usuário a base do calendário criada acima.
 - iv. Executar a função `baseCalendario` para cada uma das Cias. Aéreas e armazenar os resultados, respectivamente, nas variáveis: `cAA`, `cDL`, `cUA` e `cUS`.
 - e. Para cada uma das Cias. Aéreas, apresente o mapa de calor respectivo utilizando a combinação de camadas do `ggplot2`. Lembre-se de adicionar um título utilizando o comando `ggtitle`. Por exemplo, `cXX + pal + ggtitle("Título")`.

```
remotes::install_github("jayjacobs/ggcal")
library(ggcal)
library(ggplot2)

pal <- scale_fill_gradient(low = "#4575b4", high = "#d73027")

baseCalendario <- function(stats, cia) {
  dados_calendario <- stats %>%
    filter(Cia == cia) %>%
    select(Data, Perc)


  calendario <- ggcal(dados_calendario$Data, dados_calendario$Perc)

  return(calendario)
}
```

```
cAA <- baseCalendario(estatisticas_finais, "AA")
cDL <- baseCalendario(estatisticas_finais, "DL")
cUA <- baseCalendario(estatisticas_finais, "UA")
cUS <- baseCalendario(estatisticas_finais, "US")


cAA + pal + ggtitle("Mapa de Calor da porcentagem de voos com atraso maior
de 10 minutos da Companhia Aérea AA")
```

Mapa de Calor da porcentagem de voos com atraso maior de 10 minutos da Companhia Aérea AA




```
cDL + pal + ggtitle("Mapa de Calor da porcentagem de voos com atraso maior
de 10 minutos da Companhia Aérea DL")
```

Mapa de Calor da porcentagem de voos com atraso maior de 10 minutos da Companhia Aérea DL




```
cUA + pal + ggtitle("Mapa de Calor da porcentagem de voos com atraso maior de 10 minutos da Companhia Aérea UA")
```

Mapa de Calor da porcentagem de voos com atraso maior de 10 minutos da Companhia Aérea UA



```
cUS + pal + ggtitle("Mapa de Calor da porcentagem de voos com atraso maior  
de 10 minutos da Companhia Aérea US")
```

Mapa de Calor da porcentagem de voos com atraso maior de 10 minutos da Companhia Aérea US



```
Sys.setenv(TZ = "America/Sao_Paulo")  
Sys.time()
```

```
[1] "2026-08-22 22:58:27 -03"
```